



# **Analítica de Lealtad y Retención de Clientes en Retail Online**

*Predicción de Churn, Customer Lifetime Value y Segmentación de Clientes*

Trabajo Fin de Máster  
Opción 1 — Análisis de un dataset (orientación Data Scientist)

Autor: Jorge Allende  
Tutores: Carlos Ortega, Santiago Mota

Fecha de entrega: 17 de septiembre de 2026

# Índice

|                                                                        |           |
|------------------------------------------------------------------------|-----------|
| <b>1. Resumen Ejecutivo.....</b>                                       | <b>3</b>  |
| 1.1. Objetivo del trabajo.....                                         | 3         |
| 1.2. Enfoque.....                                                      | 3         |
| 1.3. Interpretabilidad y aplicación práctica.....                      | 3         |
| 1.4. Resultados principales.....                                       | 4         |
| <b>2. El Problema de Negocio.....</b>                                  | <b>4</b>  |
| 2.1. La economía de la retención en retail online.....                 | 4         |
| 2.2. Las decisiones que este trabajo informa.....                      | 4         |
| 2.3. Las tres preguntas encadenadas y su orden.....                    | 5         |
| 2.4. Transferibilidad a programas de fidelización.....                 | 5         |
| 2.5. Criterio de éxito declarado previo a modelar.....                 | 5         |
| <b>3. Dataset.....</b>                                                 | <b>6</b>  |
| 3.1. EDA.....                                                          | 6         |
| 3.2. Unidad de análisis y diseño de ventanas.....                      | 6         |
| <b>4. Análisis Descriptivo.....</b>                                    | <b>7</b>  |
| 4.1. RFM.....                                                          | 7         |
| 4.2. Concentración de Ingresos.....                                    | 8         |
| 4.3. Evolución temporal y estacionalidad.....                          | 8         |
| 4.4. Utilización de 16 ventanas.....                                   | 8         |
| <b>5. Transformaciones.....</b>                                        | <b>8</b>  |
| 5.1. Primeras iteraciones.....                                         | 8         |
| 5.2. Diagnóstico.....                                                  | 8         |
| 5.3. Errores y correcciones.....                                       | 9         |
| 5.4. Variables finales.....                                            | 9         |
| <b>6. Modelización.....</b>                                            | <b>10</b> |
| 6.1. Esquema de validación.....                                        | 10        |
| 6.2. ¿Quién va a dejar de comprar? (Churn).....                        | 10        |
| 6.3. Segmentación ¿A qué grupo se parece?.....                         | 11        |
| 6.4. Valor del Cliente ¿En qué orden?.....                             | 12        |
| <b>7. Interpretabilidad.....</b>                                       | <b>14</b> |
| 7.1. Riesgo de Abandono.....                                           | 15        |
| 7.2. Riesgo días sin comprar.....                                      | 16        |
| 7.3. Valor del cliente.....                                            | 16        |
| 7.4. Segmentos.....                                                    | 17        |
| 7.5. ¿Qué permite decidir la combinación de los tres modelos?.....     | 17        |
| 7.6. ¿Qué no dicen los modelos?.....                                   | 18        |
| <b>8. Productivización.....</b>                                        | <b>18</b> |
| 8.1. Flujo de extremo a extremo.....                                   | 18        |
| 8.2. Prevención de discrepancias entre entrenamiento y producción..... | 19        |
| 8.3. Ejemplo real.....                                                 | 19        |
| <b>9. Conclusiones, mejoras y caso económico.....</b>                  | <b>20</b> |
| 9.1. Respuestas a las tres preguntas.....                              | 20        |
| 9.2. Mejoras y mediciones.....                                         | 20        |
| 9.3. Caso económico ilustrativo.....                                   | 21        |
| 9.4. Limitaciones y líneas futuras.....                                | 21        |
| <b>10. Bibliografía.....</b>                                           | <b>22</b> |

# 1. Resumen Ejecutivo

## 1.1. Objetivo del trabajo

El presente trabajo tiene por objetivo desarrollar un sistema de carácter analítico que permita anticipar el abandono de clientes (*churn*) en un *ecommerce*, estimar el valor económico de cada cliente a lo largo de 90 días con la empresa, y además segmentar la base de clientes activos para orientar estrategias de retención diferenciadas. De esta forma, responde a una situación común dentro de la relación negocio - cliente: actuar frente al abandono de un cliente suele producirse cuando ya es tarde para revertirlo, por ausencia de mecanismos predictivos que permitan anticiparse a dicha situación.

## 1.2. Enfoque

Para llevar a cabo el punto anteriormente señalado, el informe se estructura en torno a tres preguntas de negocio, cada una abordada mediante técnicas de *machine learning* distintas y justificadas frente a alternativas, evitando el recurso de una única solución o *AutoML*:

- ¿Qué clientes están en riesgo de *churn*? Para esto, se construye un modelo de clasificación que estima la probabilidad de que un cliente deje de comprar en un horizonte de 90 días, a partir de su comportamiento histórico.
- ¿Cuál es el valor monetario de cada cliente? Se estima el *customer lifetime value* (CLV) de cada cliente, con el fin de priorizar el esfuerzo de retención con respecto a su impacto económico real, no tan solo a su nivel de riesgo.
- ¿Cómo segmentar la base de clientes para actuar de forma distinta? Se aplican algoritmos de *clustering* no supervisado sobre variables de comportamiento (recencia, frecuencia, valor monetario) para identificar perfiles de cliente accionables sobre los que diseñar estrategias de retención específicas.

El análisis se basa en el dataset real llamado *Online Retail II*, contiene más de un millón de transacciones de una empresa británica y de esa forma permite entender el comportamiento de sus clientes y tendencias.

## 1.3. Interpretabilidad y aplicación práctica

El modelo seleccionado para la clasificación de *churn* es un modelo *XGBoost* que se explica mediante *SHAP*. En segundo lugar, segmentación *K-Means*, por medio del perfil de media de cada cluster y finalmente el modelo CLV, mediante importancia de variables. Cada uno de los tres modelos usa así la técnica de interpretabilidad propia de su naturaleza.

#### **1.4. Resultados principales**

Con un umbral de 0,38, 59 de cada 100 clientes identificados como de riesgo efectivamente abandonan, frente al 48,8% esperado en una selección aleatoria, y el modelo logra detectar a 93 de cada 100 clientes que se marchan. Complementariamente, el modelo de gasto estima cuánto gastará un cliente en los siguientes 90 días si regresa, reduciendo el error en un 38% respecto de asumir que repetirá su gasto anterior (£672 frente a £1.084). El análisis también muestra una alta concentración de valor: 506 clientes, equivalentes al 9,6% de la base analizada, generan el 57,6% de los ingresos, pese a presentar una tasa de abandono de solo 14%. Por ello, cuando la capacidad de contacto se limita al 10%, ordenar a los clientes por su riesgo de abandono multiplicado por su gasto pasado permite concentrar 3,3 veces más valor que ordenarlos solo por riesgo. Estos componentes se integran en un prototipo que asigna una puntuación a cada cliente a partir de sus transacciones (Sección 8).

## **2. El Problema de Negocio**

#### **2.1. La economía de la retención en retail online**

Dentro del mundo de la gestión del cliente es casi imperativo afirmar que es más caro captar a un futuro cliente que mantener a uno: al prospecto hay que identificarlo y convencerlo, mientras que el existente ya no cuenta con barreras (Reichheld & Sasser, 1990). Ese principio es el estatuto principal de todo programa de fidelización y también el motivo principal de este trabajo.

Cuando un cliente presenta inactividad por un tiempo determinado, ya sea, 30, 60, 90 o 120 días es cuando se entiende un abandono y frente a esto, no es necesario proyectar un modelo matemático más que una consulta a una base de datos para contrastarlo. De la misma forma, entre más tiempo siga este cliente dormido, será directamente proporcional el costo de poder “revivirlo”. La literatura sobre modelos predictivos de retención señala precisamente esta limitación de los enfoques basados en umbrales fijos de inactividad frente a modelos probabilísticos que anticipan el riesgo de abandono antes de que este se materialice (Fader & Hardie, 2007; Verbeke et al., 2012).

#### **2.2. Las decisiones que este trabajo informa**

Lo que permite el éxito de un equipo de retención es saber a quién llamar, en qué orden, con qué perfil está hablando y cuándo realizarlo. Estas decisiones de operación son el hilo conductor del informe – cada una se resuelve, hasta donde los datos pueden resolverla.

| Decisión operativa                       | Lo que este informe entrega                | Sección |
|------------------------------------------|--------------------------------------------|---------|
| ¿A quién contacto?                       | Quién va a dejar de comprar                | 6.2     |
| ¿En qué orden, con presupuesto limitado? | Cuánto vale cada uno                       | 6.4     |
| ¿Con qué tipo de tratamiento?            | A qué grupo se parece y qué lo caracteriza | 6.3     |
| ¿Cuándo?                                 | Cuánto margen de reacción queda            | 7.2     |

*Tabla 1: Lo que responde este trabajo a la operación de retención*

### 2.3. Las tres preguntas encadenadas y su orden

En términos de fondo, la tabla 1 da origen a las tres preguntas de negocio que terminan siendo la piedra angular de este trabajo, y que se responden en un orden concreto dado la dependencia en cascada.

En primer lugar ¿Quién va a dejar de comprar? Permite saber a quién hay que priorizar. Luego ¿Cuánto vale cada cliente? Esto ayuda a comprender que no todos los clientes poseen el mismo valor. Finalmente ¿Cómo se agrupan los clientes? Esto permite determinar a quién contactar y en qué orden.

### 2.4. Transferibilidad a programas de fidelización

Tanto en las aerolíneas, la gestión de relación en banca o el mundo del retail enfrentan una misma estructura: los clientes tienen un valor desigual además de una ventana temporal corta para intervenir antes de que el *churn* no tenga reversa, y con una estrategia definida para saber a quién intentar reactivar.

Lo que realmente se transfiere es la lógica de decisión – Tener la capacidad de anticipar, valorar y agrupar, en este orden –, no los pesos del modelo. Por ejemplo, los patrones de un socio de una aerolínea no necesariamente son los mismos que los de un comprador de artículos de aseo, y cada uno de los rubros probablemente necesitará entrenar modelos bajo sus propios datos de comportamiento.

### 2.5. Criterio de éxito declarado previo a modelar

Previo a la construcción del primer modelo, este TFM fija cómo medir si de algo sirvió, en términos de unidades de negocio y no de estadística: libras protegidas por cada contacto disponible, no aquella que presente el mejor desempeño técnico. Definir este criterio de evaluación de forma previa es fundamental, ya que, una vez entrenado el modelo, siempre es posible seleccionar la métrica que más favorezca sus resultados.

### 3. Dataset

El dataset que se utilizó para la realización de este TFM es *Online Retail II*, *UCI Machine Learning Repository*. Con fechas desde diciembre de 2009 a diciembre de 2011

| Variable                                   | Contenido                                                       |
|--------------------------------------------|-----------------------------------------------------------------|
| <i>InvoiceNo / StockCode / Description</i> | Factura (empieza por «C» si es cancelación), producto y nombre. |
| <i>Quantity</i>                            | Unidades por línea. Negativo = devolución.                      |
| <i>InvoiceDate / Price</i>                 | Fecha-hora y precio unitario (£).                               |
| <i>Customer ID / Country</i>               | Cliente (ausente en parte de las filas, 3.1) y país             |

Tabla 2: Variables iniciales.

#### 3.1. EDA

El análisis principal en cuanto a eliminación son 243.000 filas que equivale al 22,8% del dataset, dado que no tienen cliente identificado. No obstante, las líneas representan el 14,3% de la facturación, sumando un total de £2,79 M. La asimetría entre ambos porcentajes revela que los clientes identificados tienen un mayor gasto que los no identificados.

En cuanto a la consistencia de los datos, se identificaron registros con cantidades negativas, lo que equivale a las devoluciones de productos, y otros con precio igual a cero que se entienden como regalos. Estos casos constituyen la señal de comportamiento más directa del conjunto de datos respecto de la calidad percibida por los clientes y sirven como base para construir la variable *return\_rate* en la fase 2.

Finalmente, luego de la limpieza de datos, el dataset contó con 824.355 líneas lo que equivale a 5.940 clientes.

#### 3.2. Unidad de análisis y diseño de ventanas

Cada fila del archivo está aperturada por compra realizada por cada cliente, pero la pregunta que se plantea es ¿Este cliente va a dejar de comprar? Una fila por cliente es poco robusta porque falta el cuándo. Nadie abandona “en general”, sino lo hace a partir de una fecha.

La fecha de observación divide el historial en dos: los seis meses previos aportan las siete variables que se conocen del cliente (recencia, frecuencia y gasto, entre otras), y los 90 días posteriores aportan la respuesta (sí no compro, es churn). Nada después del corte entra en las variables.

Es importante destacar que la fecha se desplaza mes a mes. La razón es netamente operativa: un equipo de retención no decide una vez, decide todos los meses. Dicho esto, los cortes son válidos desde el 01/06/2010 –antes no hay seis meses de historia– al 01/09/2011 –después no quedan 90 días de observación–. 16 ventanas mensuales deslizantes.

Finalmente, el panel de modelado pasa a ser 48.394 observaciones sobre 5.249 clientes identificados, entre 2.703 y 3.497 por ventana.

## 4. Análisis Descriptivo

La base está altamente concentrada y el churn no es una constante: varía entre el 38,4% y el 62,4% según el mes en que se mire.

### 4.1. RFM

El gasto promedio per cápita de todas las ventanas equivale a £1.360 con una mediana de £541 – menos del 50%. La frecuencia por su parte, obtiene el mismo patrón, es decir, una media de 2,9 transacciones y mediana de 2.

Por el contrario, la recencia de compra presenta una media equivalente de 65 días y mediana de 53 días.





Imagen 1: Panel de distribuciones RFM (recencia, frecuencia y gasto).

Como bien señala imagen 1, la recencia muestra una distribución bastante más homogénea a diferencia de la larga cola de gasto y frecuencia, lo que indica que pocos clientes gastan mucho y pocos clientes tienen alta frecuencia de compra.

#### 4.2. Concentración de Ingresos

La curva de concentración de ingresos señala que el 20% de los clientes concentra el 77% de todos los ingresos acumulados. Aquí basta con establecer que el patrón ya es visible antes de segmentar, y que prepara el argumento central del informe: El problema no está en retener a un gran volumen de personas, sino a unos pocos.

imagen 2: Concentración de ingresos



#### 4.3. Evolución temporal y estacionalidad

La tasa de *churn* depende fuertemente según el mes en el que se observa hasta en 24 puntos. En septiembre del 2010 presenta una tasa del 38,4% y un máximo de 62,4% en enero del 2011, que podría ser explicado por las campañas navideñas donde se sabe que existe un aumento de consumo en mercados de retail.

#### 4.4. Utilización de 16 ventanas

Es importante señalar que un fenómeno que varía 24 puntos no puede ser explicado con solamente una foto. De hecho, un modelo que esté medido solamente en septiembre obtendrá un valor sustancialmente mejor que uno que se realice post diciembre. Como bien explica el punto 3.2, el análisis se define utilizando 16 ventanas de observación deslizantes, cada una con su propia población de clientes activos y su tasa de churn respectiva.

## 5. Transformaciones

#### 5.1. Primeras iteraciones

En primera instancia, se intentó predecir la tasa de *churn* sobre la misma ventana temporal, es decir, observando a los clientes hacia atrás para saber si llevaban o no más de 90 días sin comprar. Una pregunta que, en realidad, se podría responder realizando consultas a una base de datos sin necesidad de aplicar un modelo predictivo.

#### 5.2. Diagnóstico

El *churn* era una función determinística de *recency\_days* (más de 90 días), verificable en el 100% de las filas: una fuga de información. Esto obligó a excluir *recency\_days*, la variable más predictiva del *RFM*, pero la respuesta seguía colándose por *customer\_age\_days*, ligada a la recencia dentro de la ventana: por sí sola alcanzaba un *ROC-AUC* de 0,781, frente al 0,792 del

modelo completo. Solo el 38% de los clientes marcados como churn lo eran realmente, lo que motivó revisar todo el análisis.

### 5.3. Errores y correcciones

Como se ha señalado a lo largo del informe, las variables se calculan sobre una ventana pasada; el resultado a predecir, sobre una ventana futura y disjunta a la anterior. Básicamente, lo que se predice nunca se está observando como se ilustra en la siguiente imagen.




Imagen 3: Línea temporal con las dos ventanas: Variables y target.

La tasa de churn y el gasto futuro (*future\_monetary\_90d*) se definen ambos sobre compras reales, de modo que siempre se cumple la relación del que abandona implica que el gasto futuro es cero. Antes de entrenar cualquier modelo se comprueba que esa equivalencia se cumple en el 100% de los casos, de lo contrario, un cliente podría figurar como “no abandona” y aun así no haber gastado nada, lo que rompería el reparto entre las secciones 6.2 y 6.4.

Otro punto de corrección fue que ahora solo se incluyen clientes con al menos una compra real. La versión anterior incluía también a quien solo había devuelto algo en la ventana, sin comprar nunca. Ese grupo generaba un segmento entero en la segmentación que no describía ningún comportamiento real de negocio: era un artefacto de cómo se había definido la población de análisis. Al corregirlo, el segmento desaparece.

### 5.4. Variables finales

| Variable                 | Qué mide                                         | Lectura de negocio                                     |
|--------------------------|--------------------------------------------------|--------------------------------------------------------|
| <i>recency_days</i>      | Días desde la última compra                      | Cuánto tiempo lleva frío el cliente                    |
| <i>frequency</i>         | Facturas de compra en la ventana                 | Cuántas veces compró, sin contar cancelaciones         |
| <i>monetary</i>          | Gasto en la ventana                              | Cuánto vale ese cliente hasta ahora                    |
| <i>return_rate</i>       | % de facturas con devolución                     | Señal de calidad percibida, no de compra               |
| <i>customer_age_days</i> | Días entre primera y última compra en la ventana | Antigüedad de la relación dentro del periodo observado |

|                                  |                               |                                         |
|----------------------------------|-------------------------------|-----------------------------------------|
| <i>avg_items_per_transaction</i> | Unidades medias por factura   | Distingue patrón minorista de mayorista |
| <i>unique_products</i>           | Productos distintos comprados | Amplitud del interés del cliente        |

Tabla 3: Variables finales, que miden y su lectura de negocio

Se descarta *avg\_order\_value* (gasto ÷ frecuencia): no es información nueva, es una división de dos variables que ya están en la lista. Añadirla no aporta nada al modelo y complica la lectura de los coeficientes.

## 6. Modelización

La sección responde a las tres preguntas planteadas en la sección 2.3 bajo un mismo esquema de validación, que se explica primero (6.1): quién va a dejar de comprar (6.2), a qué grupo se parece (6.3) y cuánto vale y en qué orden contactarlo (6.4). La segmentación se presenta antes que el valor porque no depende de los otros modelos; en cambio, 6.4 necesita la probabilidad de abandono de 6.2 para calcular el valor esperado y construir la matriz que cruza riesgo y valor. Por eso cierra la sección.

### 6.1. Esquema de validación

El reparto entre entrenamiento y evaluación se realiza a partir de las 16 ventanas mensuales de observación definidas en la sección 4.4, cuyas variables se calculan considerando los seis meses anteriores (5.3). Como se explicó previamente, las 10 ventanas más antiguas se utilizan para entrenar el modelo y las 6 más recientes para su evaluación, lo que da un conjunto de test de 17.419 observaciones.

Es importante aclarar que esto no implica entrenar diez modelos distintos, sino utilizar las diez primeras ventanas mensuales como conjunto de entrenamiento. Dentro de este conjunto, la validación cruzada se realiza agrupando por cliente. Tanto la selección del modelo como la definición del umbral se hacen durante esta etapa, sin utilizar información del conjunto de test. El test se reserva exclusivamente para la evaluación final y el reporte de resultados.

### 6.2. ¿Quién va a dejar de comprar? (*Churn*)

Según los resultados de los modelos para responder la pregunta señalada se obtiene:

| Modelo              | CV ROC-AUC    | ± sd folds     | Test ROC-AUC | Test PR-AUC  |
|---------------------|---------------|----------------|--------------|--------------|
| Regresión logística | 0,7325        | ±0,0102        | 0,747        | 0,693        |
| Random Forest       | 0,7353        | ±0,0102        | 0,749        | 0,692        |
| LightGBM            | 0,7352        | ±0,0093        | 0,749        | 0,695        |
| <b>XGBoost</b>      | <b>0,7356</b> | <b>±0,0095</b> | <b>0,749</b> | <b>0,693</b> |

Tabla 4: Métricas modelos de churn

La columna *sd folds*, permite explicar la selección de la tabla. La distancia que hay entre el peor y el mejor modelo es de 0,003, y la propia medición fluctúa en  $\pm 0,01$ . Entendiendo que las cuatro filas no son cuatro rendimientos distintos, son el mismo rendimiento medido cuatro veces. En test, tres de los cuatro comparten el mismo valor.

Si bien los modelos obtenidos en esta instancia presentan un rendimiento bastante similar, el seleccionado para continuar es *XGBoost* debido a que posee un resultado levemente superior.

Otro criterio de elegir este tipo de modelo es que nos permite realizar una interpretación efectiva utilizando un análisis *SHAP* para describir la forma del efecto de cada variable sobre el target. La segunda es la robustez del prototipo: los modelos de árbol no dependen de que las transformaciones de las variables se repliquen con exactitud en el momento de dar el score.




Imagen 4: Curva Precision-Recall y elección del umbral de decisión (XGBoost).

Como bien señala la imagen anterior, el umbral es 0,38 ya que busca maximizar el F1 sobre predicciones *out-of-fold* en entrenamiento, no sobre el *test*. Con él, obtiene las métricas *precision* 0,59 y *recall* 0,93 en test: de cada 100 clientes marcados en riesgo, 59 abandonan de verdad, y el modelo detecta 93 de cada 100 que sí lo hace, frente a un 48,8% de acierto eligiendo al azar.

### 6.3. Segmentación ¿A qué grupo se parece?

Para llevar a cabo la segmentación de clientes, se utilizó un modelo *K-Means* sobre las mismas variables transformadas, con  $k = 5$ . El *silhouette* técnico favorece  $k = 2$  (0,31 frente a 0,212 con  $k = 5$ ), pero esta división de dos tan solo es capaz de separar clientes que compran mucho frente a los que compran poco, por lo que, no distingue a un cliente valioso que se está enfriando de uno que nunca ha repetido, y esos dos casos exigen campañas opuestas. A continuación, se adjuntan las segmentaciones obtenidas.

| Segmento                | Clientes | Abandono | % facturación | Acción                     |
|-------------------------|----------|----------|---------------|----------------------------|
| VIP / mayorista         | 506      | 14%      | 57,6%         | Gestión de cuenta dedicada |
| Regulares consolidados  | 911      | 38%      | 17%           | Fidelización estándar      |
| Devoluciones frecuentes | 742      | 55%      | 7,4%          | Diagnóstico de producto    |
| Puntuales de gasto alto | 1.909    | 65%      | 14,5%         | Reactivación               |
| Compradores puntuales   | 1.181    | 73%      | 3,6%          | Solo canales automáticos   |

Tabla 5: Segmentación Clientes

Aquí cada cliente cuenta una sola vez: se le asigna el cluster en el que más veces se encuentra presente, así que la columna suma exactamente los 5.249 y la facturación no se duplica entre ventanas solapadas. Es una partición.

La columna acción es una categoría de tratamiento y define a qué tipo de campaña pertenece cada grupo.

#### 6.4. Valor del Cliente ¿En qué orden?

El gasto esperado se descompone en dos preguntas encadenadas. En primer lugar, la probabilidad de volver a comprar, calculada en la sección 6.2, multiplicada por el valor que genera el cliente al volver, que es lo que este segundo modelo estima.

Para estimar ese segundo término, se compararon cuatro modelos de regresión utilizando el mismo criterio aplicado en la sección 6.2: el mejor *RMSE* logarítmico en validación cruzada, sin considerar el conjunto de pruebas. A diferencia de la sección anterior, aquí el criterio sí logra separar con claridad a los modelos. Los tres modelos de árbol, es decir, *Random Forest*, *LightGBM* y *XGBoost* obtienen resultados prácticamente empatados entre sí, con apenas 0,24 desviaciones típicas entre el mejor y el peor, mientras que el modelo lineal *Ridge* queda claramente por debajo, a 0,8 desviaciones típicas de distancia, con un  $R^2$  en test de 0,379 que ni siquiera alcanza el 0,433 que se obtiene con solo asumir que el cliente repite su gasto pasado. Esta diferencia conlleva una implicación empresarial: mientras que la tasa de abandono depende de las variables de una manera razonablemente lineal, la regresión logística rindió casi a la par que los modelos de árboles en la sección 6.2, el gasto futuro no sigue ese mismo patrón.

El modelo seleccionado (*LightGBM*) obtiene un error medio de £672, frente a los £1.084 que resultan de asumir que el cliente repita exactamente su gasto anterior: una mejora del 38%.

Finalmente, con ambos modelos ya contruidos, es posible cruzarlos para contestar a la pregunta del título de este apartado: ¿En qué orden se debe contactar al cliente? La matriz de prioridad cruza las variables de riesgo y valor en cuatro cuadrantes, ordenados por libras en riesgo por contacto y no por valor total acumulado. Se asume que el recurso escaso es la capacidad de contacto y no el presupuesto monetario: un supuesto habitual en operaciones de retención. Partiendo de esa premisa, la pregunta relevante no es qué cuadrante acumula el mayor valor en riesgo, sino más bien cuánto valor se protege con cada contacto realizado. Un contacto es una observación cliente-ventana, no un cliente: la decisión se toma por cliente y momento, y un mismo cliente puede cambiar de cuadrante de un mes a otro. Por eso la columna de clientes distintos no es sumable. A continuación se adjunta la tabla explicativa.

| Cuadrante                            | Contactos (obs.) | Cientes distintos | Valor en riesgo | £ / contacto |
|--------------------------------------|------------------|-------------------|-----------------|--------------|
| RETENER (alto riesgo, alto valor)    | 5.105            | 1.991             | £2.630.184      | £515         |
| FIDELIZAR (bajo riesgo, alto valor)  | 3.605            | 1.012             | £1.003.937      | £278         |
| DEJAR IR (alto riesgo, bajo valor)   | 8.263            | 2.563             | £2.262.521      | £274         |
| MONITOREAR (bajo riesgo, bajo valor) | 446              | 202               | £58.312         | £131         |

Tabla 6: Matriz riesgo vs valor.

El análisis contempla 4.128 clientes reales, de los cuales 1.404 cambiaron de cuadrante a lo largo de los seis intervalos temporales. En consecuencia, la métrica de clientes distintos suma un total de 5.768 registros debido al recuento doble de aquellos que cambiaron de cuadrante y no representa a individuos únicos. Por el contrario, los 17.419 contactos constituyen registros únicos y acumulables; por ello, se utilizan para calcular el indicador de £/contacto.




Imagen 5: Matriz de priorización de retención y retorno por contacto.

Como según señala la matriz y la imagen 5, parece que da igual dónde se ponga el esfuerzo porque el valor en juego es similar. Pero como el presupuesto real es "número de contactos" (no libras), lo que importa es el rendimiento por contacto, y ahí retener es sustancialmente más eficiente.

La matriz permite identificar el cuadrante al que pertenece cada contacto, pero no establece un orden de prioridad dentro de la base de datos. Para incorporar esta dimensión, se plantea un escenario en el que solo es posible contactar al 10% de los casos.

Partiendo de este supuesto, las 17.419 observaciones del conjunto de prueba se ordenan según diversos criterios de priorización y se evalúa la proporción del valor en juego captada dentro de ese 10% seleccionado. El valor en juego corresponde al gasto acumulado durante los seis meses anteriores por aquellas observaciones que efectivamente abandonaron (*churn*), sumando un total de £5.582.966. Este monto se calcula como una suma a nivel de contacto y no como facturación única por cliente.

| Criterio              | <i>Churn</i> cada 100 contactados | Valor que entra en la lista |
|-----------------------|-----------------------------------|-----------------------------|
| Al azar               | 49                                | 10%                         |
| Solo riesgo           | 75                                | 12% (£669.956)              |
| Riesgo × gasto pasado | 37                                | 39% (£2.177.357)            |

Tabla 7: Criterio de orden con capacidad para el 10% de la base.

Ordenar sólo por riesgo es lo que más acierta, pero llena la lista de clientes de poco gasto y, en libras, apenas mejora el azar. Multiplicar el riesgo por el gasto pasado mete 3,3 veces más libras con el mismo número de contactos. La ventaja es mayor cuanto más escasa es la capacidad y baja a 1,7 veces al 50%. Si el objetivo son clientes retenidos, conviene ordenar por riesgo; si son ingresos, por riesgo × gasto. El modelo es el mismo; lo que cambia es la pregunta.

## 7. Interpretabilidad

Las tres preguntas del trabajo se responden con tres modelos, y los tres se dejan interpretar pero no de la misma manera, porque no son la misma clase de modelo:

- Riesgo de abandono (*churn*): Es el único con explicación individual: para cada cliente puede desglosarse por qué recibe el score que recibe. Se usa SHAP (Lundberg y Lee, 2017), un método que reparte la predicción entre las variables que la producen, de modo que la suma de las contribuciones reconstruye exactamente el resultado.


- Valor esperado: Admite el reparto global —qué variables sostienen la estimación— medido por ganancia: cuánto mejora el modelo cada vez que usa una variable. No baja al cliente concreto.
- Segmentación: En este punto no se busca predecir, sino, agrupar al tipo de cliente según perfil.

### 7.1. Riesgo de Abandono

El análisis SHAP permite identificar la importancia relativa de cada variable y la dirección de su impacto en el riesgo de abandono. Los resultados muestran que la frecuencia de compra y la antigüedad de la relación son los principales factores explicativos, seguidos por el gasto y la recencia. Unos niveles más elevados de actividad de compra, antigüedad, gasto y variedad de productos se asocian con un menor riesgo de abandono, mientras que un mayor número de días transcurridos desde la última compra se vincula a un riesgo más alto. La tasa de devoluciones tiene una importancia menor y muestra una asociación inversa con el abandono, en tanto que las unidades por factura no presentan una dirección estable.

| Variable                  | % de importancia | Dirección                              |
|---------------------------|------------------|----------------------------------------|
| Frecuencia de compra      | 32,1%            | Más compras → menos riesgo             |
| Antigüedad de la relación | 28,1%            | Más antigüedad → menos riesgo          |
| Gasto                     | 15,1%            | Más gasto → menos riesgo               |
| Recencia                  | 10,9%            | Más días sin comprar → más riesgo      |
| Variedad de producto      | 8%               | Más productos distintos → menos riesgo |
| Tasa de devolución        | 3,9%             | Más devoluciones → menos riesgo        |
| Unidades por factura      | 1,8%             | Sin dirección estable                  |

Tabla 8: Reparto SHAP del riesgo de abandono: cuánto pesa cada variable y hacia qué lado empuja.



En general, los resultados indican que el riesgo de abandono está asociado principalmente al nivel de actividad y al grado de vinculación del cliente con la empresa. Aquellos clientes con una menor frecuencia de compra, menor antigüedad, menor gasto y mayor tiempo transcurrido desde su última compra presentan un perfil de mayor riesgo. Por consiguiente, estas variables pueden utilizarse para priorizar las acciones de retención, especialmente en el caso de clientes que han reducido su actividad o llevan más tiempo sin realizar una compra.

El análisis debe interpretarse como una relación predictiva dentro del modelo, más que necesariamente como una relación de causalidad

## **7.2. Riesgo días sin comprar**

La variable de recencia permite identificar el momento adecuado para intervenir. A medida que aumenta el número de días sin realizar una compra, se incrementa el riesgo de abandono: este pasa del 32% en clientes con entre 0 y 30 días de inactividad al 68% en aquellos con más de 90 días. Paralelamente, el gasto medio disminuye considerablemente, pasando de £2.505 en el primer segmento a £566 en el último. El intervalo de 30 a 60 días constituye una ventana clave para la intervención, ya que la tasa de abandono supera el 40% mientras que el gasto medio se sitúa en £1.026, una cifra que justifica el coste de una iniciativa de retención. No obstante, es importante distinguir entre el momento de intervenir y a quién contactar: si bien la recencia indica el instante oportuno para actuar, la selección de clientes debe basarse en el riesgo y el valor.

## **7.3. Valor del cliente**

La predicción del gasto futuro de un cliente resulta considerablemente más sencilla que la predicción de su abandono: aproximadamente nueve de cada diez unidades de importancia del modelo se concentran en una única variable, correspondiente al gasto acumulado.

En el modelo de predicción de gasto futuro, la importancia se concentra principalmente en el gasto acumulado, que representa el 88,9% del peso total. Las unidades por factura contribuyen con un 4,6%, seguidas por la antigüedad de la relación (2,8%), la variedad de productos (1,5%), la frecuencia de compra (1,3%), la recencia (0,6%) y la tasa de devoluciones (0,3%).

A diferencia del modelo de *churn*, en el que el peso se distribuye entre varias variables, el modelo de valor concentra prácticamente toda su capacidad explicativa en una única variable. Esto explica por qué el modelo reduce significativamente el error en comparación con el simple uso del gasto histórico como estimación: el gasto acumulado sigue siendo el factor determinante de su precisión. Asimismo, pone de manifiesto que las variables que determinan el riesgo de abandono difieren de las que determinan el valor esperado, lo que implica que ambos criterios deben combinarse para establecer prioridades de intervención.

#### **7.4. Segmentos**

Los cinco grupos de la sección 6.3 no son categorías arbitrarias: están ordenados exactamente por lo que el modelo de abandono considera decisivo. Ordenados por frecuencia de compra, el abandono los sigue sin una sola excepción.

Para la empresa, los clientes VIP o mayoristas requieren una atención prioritaria a fin de no descuidar relaciones de alto valor. Los clientes habituales consolidados constituyen el núcleo del negocio y representan la mayor pérdida potencial de valor en caso de que dejen de comprar. En cuanto al segmento de clientes que devuelven con frecuencia, es preciso comprender primero las causas relacionadas con el producto antes de implementar medidas de retención. Los clientes ocasionales de alto gasto ofrecen una oportunidad atractiva de reactivación, dado que ya han demostrado capacidad de gasto. Por último, la gestión de los compradores ocasionales (que realizan una única compra) debe realizarse principalmente a través de canales automatizados, ya que el coste de una intervención personalizada podría superar el valor esperado de su recuperación.

La segmentación se realizó sin tener en cuenta quiénes abandonaron el servicio; sin embargo, los segmentos aparecen ordenados de mayor a menor según la tasa de abandono. Esto confirma en la práctica lo expuesto en la sección 7.1: los hábitos de compra no solo permiten predecir quiénes se marcharán, sino que también distinguen a unos tipos de clientes de otros.

La asimetría que revela esta tabla es la que debería determinar la asignación del presupuesto: 506 clientes generan el 57,6% de los ingresos con la tasa de abandono más baja, mientras que 3.090 compradores ocasionales generan el 18% con la tasa más alta. Tratar al segundo grupo igual que al primero es la forma más costosa de distribuir un presupuesto de retención.

#### **7.5. ¿Qué permite decidir la combinación de los tres modelos?**

Ninguno de los tres modelos basta por su cuenta, y la razón es que responden preguntas que los otros no pueden responder:

- **Modelo riesgo:** Señala al cliente cuya relación se está deteriorando, pero no si merece la pena gastarle una llamada.
- **Modelo de valor:** Un abandono probable de un cliente que gasta £175 no es el mismo problema que uno de £5.588, aunque el score de riesgo sea idéntico.
- **Modelo de segmentación:** El segmento clasifica a los clientes según su comportamiento de compra, permitiendo definir tratamientos diferenciados. El modelo los agrupa por similitud y asigna un número de grupo; luego, el análisis del perfil de cada grupo permite distinguir, por ejemplo, entre un cliente frecuente y uno ocasional.

Por ejemplo, un cliente catalogado VIP rara vez aparece en una lista ordenada por riesgo —su abandono es del 14% y sin embargo es donde está el 57,6% de la facturación; un comprador puntual encabeza cualquier lista de riesgo —73%— y es justo donde el presupuesto rinde menos. Ordenar sólo por riesgo llevaría a gastar el grueso del esfuerzo en el grupo que aporta el 3,6% de los ingresos. Por eso la matriz de prioridad de la sección 6.4 ordena por libras en riesgo por contacto y no por probabilidad de abandono.

Hay además una consecuencia práctica que sostiene la sección 8: los tres modelos leen las mismas siete variables. No hay tres sistemas que mantener sincronizados, hay un único cálculo de variables y tres lecturas distintas de él.

### **7.6. ¿Qué no dicen los modelos?**

Los tres métodos no predicen qué sucedería si se modifica una variable. Distribuyen el score entre las variables que influyen en él y responden a: ¿por qué este cliente obtiene este resultado?, no a: ¿qué pasaría si intervenimos sobre esta variable? Esta diferencia es clave para retención:

- El hecho de que la frecuencia sea la variable más influyente no significa que generar una compra adicional reduzca el riesgo en esa misma proporción. Puede ser un indicador del vínculo con la marca, no la causa del mismo.
- El hecho de que las devoluciones se asocien a tasas de abandono más bajas no implica fomentarlas, sino más bien evitar penalizar a quienes las realizan.
- Que un segmento presente mayor abandono no significa que deba priorizarse automáticamente. El punto 7.5 lo señala.

Para medir el efecto de una intervención, es necesario compararla con un grupo que no la reciba. Ese diseño no forma parte de este estudio (9.4). Lo que sí ofrece esta sección es trazabilidad: cada puntuación puede desglosarse, cada segmento posee un perfil interpretable y las decisiones se basan en modelos auditables.

## **8. Productivización**

### **8.1. Flujo de extremo a extremo**

El proceso transforma las transacciones en una recomendación de negocio a través de cinco etapas: generación de variables del cliente, estimación de la probabilidad de abandono, cálculo del valor esperado de una posible recuperación, asignación de un cuadrante de prioridad y definición de la acción recomendada.

El sistema utiliza directamente el historial de compras extraído del sistema de ventas y ejecuta estas etapas de forma automática, sin requerir cálculos ni intervención manual por parte del usuario.

El flujo de trabajo se implementa como un servicio a través de una interfaz web minimalista construida sobre una API. Esta API permite enviar información del cliente y obtener su nivel de riesgo, el valor esperado y la decisión recomendada.

El servicio se entrega además empaquetado en un contenedor Docker, de modo que puede ejecutarse en cualquier equipo con un único comando; la orquestación en producción (despliegue y escalado en varios servidores) queda fuera del alcance de este trabajo.

## **8.2. Prevención de discrepancias entre entrenamiento y producción**

Al pasar un modelo a producción, la práctica habitual consiste en escribir la lógica de cálculo de variables dos veces: una en el *notebook* de entrenamiento y otra en el sistema de inferencia en tiempo real. Si ambas versiones no coinciden exactamente, el modelo recibe datos de producción distintos a los que aprendió a interpretar; se trata de una discrepancia silenciosa, sin errores visibles, que constituye la causa más frecuente por la que un modelo funciona en el *notebook* pero falla en producción.

Este prototipo evita el problema por diseño: no se reimplementa la etapa de transacciones a variables, sino que se invoca la misma función utilizada para generar las variables de entrenamiento en la fase 2.

## **8.3. Ejemplo real**

El cliente 16062 fue puntuado el 10 de diciembre de 2011 utilizando su histórico real de compras de los seis meses anteriores. Registraba una recencia de 10 días, dos compras, un gasto acumulado de £575,44, una tasa de devolución del 0% y 38 productos distintos adquiridos. El modelo estimó un riesgo de abandono del 53% y un valor potencial de £583,94 si volvía a comprar, equivalente a un valor esperado de £273,88 y £310,06 en valor en riesgo. Por estos resultados, la decisión recomendada fue retener, mediante un contacto personalizado con una oferta, ya que representa una oportunidad eficiente para utilizar el presupuesto de retención.

En términos de limitaciones, el prototipo puede puntuar al 59% de los clientes del histórico (3.482 de 5.940), los que tienen al menos una compra en los seis meses previos a la fecha de puntuación.

## 9. Conclusiones, mejoras y caso económico

### 9.1. Respuestas a las tres preguntas

¿Quién dejará de comprar? Esto puede predecirse con un margen razonable aunque no con certeza, ya que, presenta un *ROC-AUC* de 0,75 en el conjunto de prueba (Sección 6.2). Con un umbral de 0,38, de cada 100 clientes identificados como de riesgo, 59 efectivamente abandonan la marca frente al 48,8% en una selección aleatoria y el modelo detecta a 93 de cada 100 que se marchan. Si la capacidad se limita al 10% de la base de clientes y la lista se ordena según el riesgo, 75 de cada 100 clientes contactados abandonan, frente a los 49 que lo hacen con una selección aleatoria (Sección 6.4, Tabla 7).

¿Cuál es el valor de cada cliente? El modelo de gasto estima cuánto gastará un cliente en los próximos 90 días si vuelve, con un margen de error un 38% menor que el que se obtendría simplemente asumiendo que repetirá su gasto anterior (£672 frente a £1.084; véase la sección 6.4). Esto representa un valor trimestral, más que un valor de vida útil completo. Su limitación se expone en la sección 7.3: el 88,9% de su relevancia deriva del gasto acumulado; por tanto, aunque asigna una cifra monetaria a cada cliente, dicha cifra se basa en información que, en gran medida, ya está presente en su historial de gastos previos.

¿Cómo se agrupan para la acción? En cinco segmentos, dominados por uno en particular: 506 clientes —el 9,6% de la base analizada— generan el 57,6% de los ingresos, con una tasa de abandono del 14% (Sección 6.3). Esta concentración ya era evidente antes de la segmentación (Sección 4.2); lo que esta aporta es una tipología que una simple clasificación por gasto no logra distinguir —como los 742 clientes del segmento de compras frecuentes y devoluciones o los 1.909 compradores ocasionales de alto gasto—, requiriendo cada uno de ellos campañas diferentes.

Dos hallazgos modifican el enfoque que deberían adoptar los esfuerzos. Aunque inicialmente la tasa de devoluciones se planteó como un indicador de calidad percibida (Sección 5.4), realizar devoluciones se asocia en realidad con una menor tasa de abandono (Sección 7.1). Además, el cliente que abandona es aquel que pierde el hábito de compra: la frecuencia de la relación y la antigüedad representan el 60% de la importancia en el modelo de abandono, mientras que la recencia supone el 10,9% (Sección 7.1). El sistema completo funciona como un prototipo que asigna una puntuación al cliente en función de sus transacciones (Sección 8).

### 9.2. Mejoras y mediciones

Cuando la capacidad de contacto se limita al 10%, priorizar por riesgo de abandono multiplicado por el gasto pasado permite captar 3,3 veces más valor que clasificar únicamente según el riesgo.

Esto refuerza la necesidad de analizar conjuntamente el riesgo y el valor: los clientes con mayor probabilidad de abandonar la marca no son necesariamente aquellos que generan el mayor impacto económico. El análisis de recencia (sección 7.2) también permite identificar el momento adecuado para actuar: tras un periodo de 30 a 60 días sin realizar compras, la tasa de abandono supera el 40%, si bien el gasto medio (1.026 £) sigue justificando una intervención.

Por último, se corrige la fuga de información reduciendo el valor de ROC-AUC de 0,792 a 0,749. Aunque la métrica es menor, representa una estimación más realista del rendimiento del modelo con clientes y periodos temporales no vistos previamente, lo que constituye una mejora metodológica clave del estudio.

### 9.3. Caso económico ilustrativo

El criterio de éxito fijado antes de modelar son las libras por contacto disponible (sección 2.5). El trabajo lo responde con dos resultados de la sección 6.4:

- Qué tipo de cliente rinde más por contacto (Tabla 6). El cuadrante RETENER reúne 5.105 contactos y £2.630.184 de valor en riesgo: £515 por contacto.
- Cuánto valor entra en una lista limitada (Tabla 7). Con capacidad para el 10% de la base, ordenar por riesgo  $\times$  gasto pasado mete en la lista £2.177.357 de los £5.582.966 en juego, frente a £669.956 ordenando sólo por riesgo.

Las dos cifras no se suman ni se comparan entre sí. El valor en riesgo de la Tabla 6 es una predicción: un riesgo estimado basado en un valor estimado. La cifra de £5.582.966 de la Tabla 7 representa el gasto observado de clientes que efectivamente abandonaron el servicio, agregado por contactos; dado que un mismo cliente aparece en múltiples ventanas y se contabiliza en cada una de ellas, la cifra no representa un caso único de pérdida de ingresos.

Se trata de valor identificado, no de valor recuperado, y esta distinción es más importante que las cifras. Pasar de uno a otro requiere conocer la tasa de conversión de la campaña: la proporción de personas contactadas que modifican su comportamiento como consecuencia de dicho contacto. Lo que este trabajo sí deja es la regla para decidir: un contacto del cuadrante RETENER lleva £515 de valor en riesgo, así que la campaña compensa si su coste por contacto es menor que  $\text{£}515 \times \text{tasa de conversión} \times \text{margen de la empresa}$ . Las dos últimas las tiene que poner el negocio.

### 9.4. Limitaciones y líneas futuras

La principal limitación es la ausencia de validación causal (secciones 7.6 y 9.3): el modelo predice qué clientes abandonan el servicio, pero no si una campaña logrará evitarlo. Por tanto, el siguiente paso más valioso consiste en realizar un *A/B test* con un grupo de control, lo que

permitirá transformar el valor identificado en valor efectivamente recuperado y medir el impacto real de las acciones de retención.

La capacidad predictiva también está limitada por la información disponible. Utilizando únicamente siete variables transaccionales, cuatro modelos de distintas familias arrojan resultados prácticamente idénticos, con una diferencia de apenas 0,002 en el valor *ROC-AUC* (Tabla 4, Sección 6.2). Esto sugiere que el margen de mejora reside principalmente en la incorporación de nuevas señales como el canal de adquisición, las incidencias y la respuesta a campañas más que en probar algoritmos adicionales. Asimismo, el gasto histórico utilizado como indicador indirecto del valor (Sección 6.4) podría sustituirse por una estimación del valor a largo plazo, comparando al mismo tiempo la propuesta de priorización con criterios no basados en modelos.

Por último, existen oportunidades de mejora en cuanto a la segmentación y la caracterización. La antigüedad debería reconstruirse a partir de la compra inicial real, en lugar de limitarse únicamente a la ventana de seis meses (Sección 5.4), y el enfoque de segmentación podría compararse con métodos más flexibles que K-Means, como las mezclas gaussianas. Ampliar el alcance para incorporar datos de campañas permitiría, además, traducir cada segmento en acciones concretas de retención, identificando la oferta, el canal y el mensaje que mejor funcionan para cada perfil.

## 10. Bibliografía

Chen, D. (2019). Online Retail II [Conjunto de datos]. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/502/online+retail+ii>

Fader, P. S., y Hardie, B. G. S. (2007). How to project customer retention. *Journal of Interactive Marketing*, 21(1), 76–90.

Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.

Reichheld, F. F., y Sasser, W. E. (1990). Zero defections: Quality comes to services. *Harvard Business Review*, 68(5), 105–111.

Verbeke, W., Dejaeger, K., Martens, D., Hur, J., y Baesens, B. (2012). New insights into churn prediction in the telecommunication sector: A profit driven data mining approach. *European Journal of Operational Research*, 218(1), 211–229.